



École nationale des ponts et chaussées

Projet de département IMI - 2025-2026

Erwann CARN
Ferdinand FLEURY-DAVID
Omar TOUFELAZ
Mohamed Salim, ASSELLALOU

Sous la direction de : Sibor CHENG
Laboratoire : CEREAS

Reconstruction et prévision de champs atmosphériques
à partir de capteurs éparés par tessellation de Voronoï
et apprentissage profond

Remerciements

Nous tenons à remercier l'École nationale des ponts et chaussées, et plus précisément le département d'Ingénierie mathématique et informatique, de nous permettre de travailler sur des thématiques intéressantes et actuelles, faisant l'objet d'une recherche scientifique abondante. Nous remercions plus particulièrement Éric Duceau, président du département, David Gontier, responsable académique, et Sandrine Guillerm, inspectrice des études.

Nous remercions chaleureusement Sibó Cheng, notre tuteur au CEREa, pour la qualité de son encadrement, ses conseils méthodologiques et la régularité de nos échanges tout au long de ce projet.

Table des matières

1	Introduction	5
2	Description et analyse des données	6
2.1	Présentation du jeu ERA5	6
2.2	Analyse de la variabilité des données	6
2.3	Découpage temporel et justification	6
2.4	Contraintes matérielles et sous-échantillonnage	7
3	Formalisation du problème et méthodologie	7
3.1	Notations et cadre général	7
3.2	Reconstruction de champs denses depuis des capteurs épars	8
3.2.1	Prétraitement : tessellation de Voronoï	8
3.2.2	Réseau de neurones pour la reconstruction	9
3.3	Prévision déterministe	11
3.3.1	Modèle de prévision et rollout autorégressif	11
3.3.2	Prévision à long terme : teacher forcing (push-forward)	12
3.4	Prévision probabiliste par interpolant stochastique	13
3.4.1	Motivation	13
3.4.2	Modèle, entraînement et inférence	14
3.5	Évaluation de la chaîne complète	15
4	Résultats	15
4.1	Métriques d'évaluation	15
4.2	Reconstruction	15
4.2.1	Résultats à 10 % de capteurs	15
4.2.2	Résultats visuels	16
4.2.3	Robustesse au taux d'observation	16
4.3	Prévision déterministe à 24 heures	18
4.3.1	Résultats depuis un champ dense	18
4.3.2	Impact de la reconstruction sur la prévision	18
4.3.3	Prévision autoregressive sur 7 jours	19
4.3.4	Résultats visuels	19
4.4	Prévision probabiliste par interpolant stochastique	20
4.4.1	Protocole et entraînement	20
4.4.2	Prévision dense à +24 h	21
4.4.3	Choix du schéma d'inférence	21
4.4.4	Ensemble et incertitude	22
4.4.5	Stabilité en rollout multi-journalier	23
5	Analyse critique	24
5.1	Difficultés	24
5.2	Critique des choix méthodologiques	24
5.3	Positionnement des résultats	25
5.4	Apports par rapport à l'état de l'art	25
6	Conclusion et perspectives	26
	Organisation du projet	26

A	Détails du réseau de reconstruction	28
A.1	Table d'architecture	28
A.2	Skip connections et connexions denses	28
A.3	Module d'attention CBAM	28
B	Métriques d'évaluation	29
B.1	NRMSE (Normalized Root Mean Square Error)	29
B.2	ACC (Anomaly Correlation Coefficient)	30
B.3	SSIM (Structural Similarity Index)	30
C	Hyperparamètres d'entraînement	31

1 Introduction

La prévision météorologique repose sur la connaissance précise de l'état de l'atmosphère à un instant donné : température, vent, pression, humidité. En pratique, ces grandeurs ne sont mesurées qu'en un nombre limité de points (stations au sol, radiosondes, bouées océaniques), et l'on cherche à reconstituer l'ensemble du champ atmosphérique à partir de ces observations partielles. Ce problème de *reconstruction depuis des mesures éparses* est central en géophysique et en sciences de l'atmosphère.

Les méthodes classiques d'interpolation (krigeage, estimation stochastique) supposent généralement des propriétés statistiques connues du champ sous-jacent, ce qui limite leur applicabilité face aux dynamiques non linéaires de l'atmosphère. Les approches par apprentissage profond ont montré leur capacité à capturer ces non-linéarités, notamment dans le domaine de la super-résolution de champs turbulents. Toutefois, la plupart de ces méthodes supposent des données disposées sur une grille régulière, ce qui ne correspond pas à la réalité des réseaux d'observation.

Fukami et al. [Fuk+21] proposent de lever cette contrainte en combinant une tessellation de Voronoï, qui associe à chaque point non observé la valeur du capteur le plus proche, avec un réseau de neurones convolutif (CNN). Cette idée simple permet de transformer un ensemble de mesures éparses en une image structurée, directement exploitable par un CNN. Leurs résultats, validés sur des écoulements fluides et des données océaniques, constituent le point de départ de notre projet.

Sur le plan de la prévision, les modèles d'apprentissage profond ont récemment atteint des performances comparables aux meilleurs systèmes numériques : GraphCast [Lam+23] et Pangu-Weather [Bi+23] surpassent le modèle opérationnel de l'ECMWF sur plusieurs variables à des horizons de 1 à 10 jours. Ces modèles opèrent cependant sur des champs denses et complets : ils supposent que l'état initial est parfaitement connu, ce qui n'est pas le cas en pratique. Notre travail s'attaque à ce maillon manquant : reconstruire l'état initial depuis des observations éparses avant de prévoir.

Notre travail s'inscrit dans le cadre du benchmark WeatherBench 2 [Ras+24], qui fournit un protocole standardisé pour l'évaluation des modèles de prévision météorologique par apprentissage. WeatherBench 2 définit les données de référence (réanalyse ERA5), les métriques d'évaluation (RMSE, ACC, SSIM), les horizons temporels cibles et les baselines à surpasser (persistance, climatologie). Nous l'adoptons comme cadre méthodologique pour garantir la reproductibilité et la comparabilité de nos résultats. Nous développons une chaîne de traitement en deux étapes :

1. **Reconstruction** : estimer un champ atmosphérique complet à partir de seulement 10 % des points d'une grille 64×32 ;
2. **Prévision** : prédire l'évolution de l'atmosphère à partir du champ reconstruit, de +24 h jusqu'à +10 jours. Nous l'abordons de deux manières : un modèle *déterministe*, entraîné par teacher forcing (push-forward) pour stabiliser le rollout autorégressif, et un modèle *probabiliste* par interpolant stochastique, qui échantillonne un ensemble de scénarios et fournit une carte d'incertitude.

Le CEREa nous a soumis la question suivante : peut-on apprendre, depuis des observations atmosphériques très partielles, à la fois à reconstituer un champ global et à prévoir son évolution ? Nous avons reformulé ce problème en deux sous-tâches découplées mais couplées en pipeline : une tâche de reconstruction supervisée (10 % de points $\rightarrow$ champ dense) et une tâche de prévision (champ dense $\rightarrow$ +24 h). Ce découplage nous a permis d'évaluer séparément chaque maillon et d'identifier où l'erreur se propage.

Notre travail s'inscrit dans une démarche d'apprentissage par la pratique : il s'agissait pour nous de nous approprier des méthodes actuelles de l'apprentissage profond appliqué aux sciences de l'atmosphère, en les implémentant et en les testant sur des données réelles. Le CEREa nous a fourni un cadre scientifique stimulant et des orientations méthodologiques, mais la valeur du projet réside avant tout dans la démarche : comprendre pourquoi et comment ces méthodes

fonctionnent, identifier leurs limites par l’expérience, et développer un regard critique sur les choix techniques. En ce sens, les résultats obtenus, une reconstruction atteignant un ACC de 0,871 à 10 % de capteurs, une prévision déterministe surpassant la persistance de -34% et une prévision probabiliste de $-34,8\%$ en NRMSE à +24 h, sont autant des preuves de concept que des illustrations des possibilités et limites de ces méthodes.

Ce rapport présente les données utilisées (section 2), la formalisation du problème et les choix méthodologiques (section 3), les résultats de reconstruction, de prévision déterministe et probabiliste (section 4.1), une analyse critique (section 5), et nos conclusions et perspectives (section 6).

2 Description et analyse des données

2.1 Présentation du jeu ERA5

Les données utilisées proviennent de la réanalyse ERA5, produite par le Centre européen pour les prévisions météorologiques à moyen terme (ECMWF). ERA5 combine des observations réelles (stations, satellites, radiosondes) avec un modèle de prévision numérique pour produire un état atmosphérique cohérent sur l’ensemble du globe, à intervalles réguliers de 6 heures. Ce jeu de données couvre la période 1959–2022, soit plus de 60 ans de données.

Nous utilisons la version sous-échantillonnée à une résolution de 64×32 points de grille (environ $5,6^\circ \times 5,6^\circ$), fournie par le benchmark WeatherBench 2 [RHM+24]. Cette résolution réduite permet un entraînement sur des machines personnelles, mais implique que les phénomènes de petite échelle (orages, fronts locaux) sont lissés.

2.2 Analyse de la variabilité des données

Le jeu de données présente une variabilité importante, qu’il convient de caractériser pour évaluer la pertinence de notre approche.

Variabilité temporelle. Les cinq variables présentent des cycles saisonniers marqués : la température T_{2m} varie de plusieurs dizaines de degrés entre été et hiver aux hautes latitudes ; le géopotentiel z_{850} reflète les variations de pression atmosphérique associées aux saisons. L’humidité spécifique q_{850} est fortement liée à la température via la relation de Clausius-Clapeyron, et présente donc une forte saisonnalité dans les régions tropicales et tempérées.

Corrélations inter-variables. Les cinq variables ne sont pas indépendantes : la température et l’humidité sont physiquement couplées, et le vent est lié au gradient de pression via la relation géostrophique. Cependant, à la résolution grossière de notre grille et avec seulement 10 % de points observés, exploiter ces corrélations par un CNN local s’avère difficile, ce que nos expériences confirment .

Configurations extrêmes. Le jeu ERA5 contient des événements météorologiques extrêmes (tempêtes, canicules, vagues de froid) dont la fréquence est par nature faible. Le modèle est donc exposé à un déséquilibre : les configurations atmosphériques « normales » dominent l’entraînement, tandis que les situations extrêmes souvent les plus critiques pour la prévision opérationnelle sont sous-représentées.

2.3 Découpage temporel et justification

Dans les expériences considérées ici, on ne retient que les $N = 4000$ premiers pas de temps du jeu de données, correspondant à des observations 6-horaires allant du 1^{er} janvier 1959 au

26 septembre 1961. Le découpage temporel est ensuite effectué chronologiquement selon une répartition 70/15/15 :

- **Entraînement** (70 %, soit 2800 pas de temps) : du 1^{er} janvier 1959 au 30 novembre 1960
- **Validation** (15 %, soit 600 pas de temps) : du 1^{er} décembre 1960 au 29 avril 1961
- **Test** (15 %, soit 600 pas de temps) : du 30 avril 1961 au 26 septembre 1961

Ce découpage appelle plusieurs remarques.

Pourquoi un découpage chronologique ? Contrairement à un mélange aléatoire, le découpage chronologique garantit qu’aucune information future ne fuit vers l’entraînement. Cette propriété est essentielle dès lors que l’on s’intéresse à des tâches où la structure temporelle des données doit être respectée.

Pourquoi 70/15/15 ? Cette répartition constitue un compromis classique en apprentissage automatique : la majeure partie des données est consacrée à l’entraînement, tandis que des ensembles distincts sont réservés à la validation et au test. Dans notre cas, cela correspond respectivement à 2800, 600 et 600 pas de temps.

Limites. Ce sous-échantillonnage à $N = 4000$ ne couvre qu’une fenêtre temporelle relativement courte, d’environ trois ans. Le modèle n’est donc pas entraîné sur la diversité complète des situations météorologiques présentes dans l’ensemble ERA5 total. En particulier, ce protocole ne permet pas d’étudier des effets de variabilité climatique à long terme.

2.4 Contraintes matérielles et sous-échantillonnage

Le volume complet du jeu ERA5 à notre résolution dépasse la capacité mémoire de nos machines personnelles. Nous travaillons donc sur un sous-ensemble temporel réduit, ce qui limite la diversité des régimes atmosphériques vus à l’entraînement.

La normalisation (centrage-réduction) est calculée *exclusivement* sur le jeu d’entraînement, puis appliquée identiquement aux jeux de validation et de test, afin d’éviter toute fuite d’information statistique.

3 Formalisation du problème et méthodologie

3.1 Notations et cadre général

On considère un champ atmosphérique à un instant t , représenté par une grille régulière de $H = 32$ points en latitude et $W = 64$ points en longitude, pour $K = 5$ variables physiques : la température à 2 mètres du sol (T_{2m}), les deux composantes horizontales du vent à 10 mètres (u_{10}, v_{10}), le géopotential à 850 hPa (z_{850}) et l’humidité spécifique (q_{850}). L’état complet est donc un tenseur $X_t \in \mathbb{R}^{K \times H \times W}$.

À chaque instant, on suppose que seule une fraction des points de grille est observée : typiquement $[0, 10 \times H \times W] \approx 204$ points, soit environ 10 % de la grille. Ces points sont définis par un masque binaire $M \in \{0, 1\}^{H \times W}$, tiré aléatoirement. Ce tirage aléatoire simule un réseau de stations dont la disposition varie dans le temps.

Notre chaîne de traitement opère en deux phases : (1) reconstruire un champ dense à partir des observations éparées, puis (2) prévoir l’évolution temporelle de ce champ. Les sections suivantes détaillent chacune de ces phases.




FIGURE 1 – Pipeline complet en deux étapes. Les observations éparses (10 % de la grille) sont d’abord interpolées par tessellation de Voronoï, puis le réseau de reconstruction f_θ (U-Net++) produit un champ dense $\hat{X}_t$. La prévision est ensuite abordée de deux manières : un réseau déterministe g_ϕ qui prédit l’état à +24h et peut être appliqué de façon autorégressive (rollout) jusqu’à +10 jours, et un modèle génératif par interpolant stochastique qui apprend un chemin continu de X_t vers X_{t+24h} , dont l’intégration produit un ensemble de prévisions et une carte d’incertitude.

3.2 Reconstruction de champs denses depuis des capteurs épars

3.2.1 Prétraitement : tessellation de Voronoï

Pour transformer les mesures éparses en une entrée exploitable par un réseau de neurones, on utilise une **tessellation de Voronoï** : pour chaque point non observé, on lui attribue la valeur du capteur le plus proche (au sens de la distance euclidienne sur la grille). Concrètement, cela revient à une interpolation par plus proche voisin, calculée efficacement via un arbre de recherche spatiale (cKDTree).

Formellement, étant donné un ensemble de n capteurs positionnés en $\{s_1, \dots, s_n\} \subset \mathbb{R}^2$, la cellule de Voronoï associée au capteur s_i est définie par :

$$\mathcal{V}(s_i) = \{x \in \mathbb{R}^2 \mid \|x - s_i\|_2 \leq \|x - s_j\|_2, \forall j \neq i\} \quad (1)$$

Pour chaque variable k , on construit ainsi une image $V_t^{(k)}$ en affectant à chaque point x de la grille la valeur du capteur le plus proche :

$$V_t^{(k)}(x) = X_t^{(k)} \left(\arg \min_{s_i} \|x - s_i\|_2 \right) \quad (2)$$

On construit également un masque $M^{(k)}$ (indiquant les points observés) et une carte $S_t^{(k)}$ des valeurs observées. Le réseau de reconstruction f_θ reçoit en entrée la concaténation de ces triplets pour les 5 variables (soit $3 \times 5 = 15$ canaux) et produit en sortie le champ dense estimé $\hat{X}_t$.




FIGURE 2 – Illustration du pipeline Voronoï + CNN pour la reconstruction de champs depuis des capteurs épars. L'image de Voronoï et le masque d'observation sont concaténés et passés dans un CNN pour produire le champ dense reconstruit. Figure tirée de [Fuk+21].

3.2.2 Réseau de neurones pour la reconstruction

Entrée et sortie du réseau. Le réseau de reconstruction f_θ reçoit en entrée, pour chacune des 5 variables atmosphériques, trois canaux d'information : le champ interpolé par Voronoï (la mosaïque grossière décrite ci-dessus), le masque binaire indiquant quels points sont réellement observés, et les valeurs brutes mesurées aux capteurs. Au total, l'entrée est un tenseur de $3 \times 5 = 15$ canaux, de dimension $15 \times 32 \times 64$. En sortie, le réseau produit le champ atmosphérique reconstruit $\hat{X} \in \mathbb{R}^{5 \times 32 \times 64}$, c'est-à-dire les 5 variables sur l'ensemble de la grille.

Pourquoi un réseau encodeur-décodeur ? La reconstruction depuis une image de Voronoï consiste à transformer une image « en mosaïque » (des régions uniformes séparées par des frontières nettes) en un champ lisse et physiquement cohérent. Ce problème s'apparente à la fois à du débruitage d'image et à de la super-résolution : il faut retrouver des structures détaillées à partir d'une information grossière. Ce constat a orienté notre recherche d'architecture : la littérature en super-résolution et en reconstruction de champs physiques converge largement vers les réseaux encodeur-décodeur avec connexions directes, capables d'opérer simultanément à plusieurs échelles spatiales. Le choix du U-Net a ainsi émergé de notre revue de littérature, en cohérence avec les recommandations de notre encadrant.

L'article de Fukami et al. [Fuk+21] utilise pour cela un réseau convolutif (CNN) à 9 couches empilées les unes après les autres, sans raccourci entre couches éloignées. Ce type d'architecture souffre d'une limitation fondamentale : chaque couche ne communique qu'avec ses voisines immédiates, si bien que l'information d'un capteur ne se propage que sur un voisinage local de l'image. Or les champs atmosphériques présentent des structures qui s'étendent sur des dizaines de points de grille : un anticyclone couvre typiquement un quart de l'hémisphère à notre résolution. Pour capter ces grandes structures tout en préservant les détails fins (fronts de température, gradients de vent), il faut une architecture capable d'opérer simultanément à plusieurs échelles spatiales.

C'est précisément ce que permet l'architecture U-Net [RFB15], conçue à l'origine pour la segmentation d'images médicales et largement adoptée dans les tâches de reconstruction de champs. Elle repose sur deux branches complémentaires :

- Un **encodeur** qui compresse progressivement l'image par des opérations de réduction de résolution (*pooling*). À chaque niveau, le réseau « voit » des structures de plus en plus grandes : les premières couches détectent les gradients locaux, les couches profondes captent les masses d'air à l'échelle continentale.
- Un **décodeur** qui reconstruit progressivement la résolution d'origine en remontant les niveaux.

- Des **connexions directes** (*skip connections*) entre l’encodeur et le décodeur à chaque niveau de résolution. Sans ces connexions, les détails fins seraient perdus lors de la compression ; avec elles, le décodeur peut combiner le contexte global (issu des couches profondes) et les détails locaux (conservés par les raccourcis).

Nos expériences confirment cet avantage : le CNN séquentiel de Fukami obtient un NRMSE moyen de 0,352 contre 0,278 pour notre modèle sur les mêmes données (cf. section 4.1).

Enrichissements de l’architecture. Nous utilisons une variante enrichie du U-Net, appelée U-Net++ [Zho+18], à 3 niveaux de compression ($32 \times 64 \rightarrow 16 \times 32 \rightarrow 8 \times 16 \rightarrow 4 \times 8$ au niveau le plus compressé). Par rapport au U-Net classique, trois améliorations principales sont apportées :

1. **Connexions denses multi-échelles.** Dans un U-Net classique, chaque niveau du décodeur ne reçoit d’information que du niveau symétrique de l’encodeur. Dans notre architecture, le décodeur reçoit également des informations provenant d’autres niveaux de résolution, ce qui enrichit la reconstruction en combinant des structures de tailles différentes. C’est l’apport principal du U-Net++ par rapport au U-Net standard.
2. **Modules d’attention (CBAM).** [Woo+18] Après chaque bloc de convolutions, un petit module d’attention apprend automatiquement à pondérer l’information selon deux axes : d’une part, *quels canaux* (c’est-à-dire quelles variables ou quelles caractéristiques intermédiaires) sont les plus utiles à cet endroit du réseau ; d’autre part, *quelles zones spatiales* de la carte méritent le plus d’effort de reconstruction. En pratique, ce mécanisme aide le réseau à concentrer ses ressources sur les zones où l’interpolation de Voronoï est la plus approximative et sur les variables les plus difficiles à reconstruire. Le détail technique du module CBAM est présenté en annexe A.3.
3. **Régularisation.** Pour éviter que le réseau ne mémorise les configurations spécifiques des données d’entraînement au lieu d’apprendre des motifs généralisables, 30 % des neurones de la couche la plus compressée sont aléatoirement désactivés à chaque itération d’entraînement (technique dite de *dropout*). Chaque bloc convolutif utilise par ailleurs des connexions résiduelles, qui facilitent la circulation des gradients lors de l’optimisation.

Le détail complet de l’architecture (résolutions, nombres de canaux par niveau, nombre de paramètres) est donné en annexe A. La figure 3 en donne une vue d’ensemble.

Fonction de coût. La fonction de coût guide l’apprentissage en mesurant l’écart entre le champ reconstruit et la vérité terrain ERA5. Elle combine trois termes complémentaires :

$$\mathcal{L}_{\text{recon}} = \alpha \cdot \text{MSE}_{\text{non-obs}} + (1 - \alpha) \cdot \text{MSE}_{\text{global}} + \lambda_{\nabla} \cdot \mathcal{L}_{\nabla} \quad (3)$$

Le premier terme, pondéré à $\alpha = 0,8$, mesure l’erreur quadratique moyenne sur les 90 % de points *non observés* : ce sont les points que le réseau doit véritablement deviner, et il est naturel de leur accorder la priorité. Le deuxième terme ($1 - \alpha = 0,2$) mesure l’erreur sur l’ensemble du champ, y compris les points observés, afin de garantir la cohérence globale de la reconstruction. Le rapport 80/20 entre ces deux termes a été choisi empiriquement.

Le troisième terme, la *pénalité de gradient spatial* $\mathcal{L}_{\nabla} = \|\nabla \hat{X} - \nabla X\|^2$, pénalise les écarts entre les gradients spatiaux du champ reconstruit et ceux de la vérité terrain. Sans ce terme, le réseau tend à produire des champs trop lisses, dans lesquels les fronts de température et les gradients de vent sont atténués. Le poids λ_{∇} a été ajusté par validation croisée.

Limites de ces choix. L’architecture reste fondée sur des convolutions locales. À notre résolution (64×32), le bottleneck atteint 4×8 , ce qui permet au réseau de capter des structures à l’échelle du continent. Toutefois, les corrélations à très longue portée (par exemple entre les deux




FIGURE 3 – Architecture du réseau de reconstruction (U-Net++ avec attention CBAM). L’encodeur compresse progressivement la résolution tandis que le décodeur la reconstruit. Les connexions directes (traits pointillés) relient chaque niveau de l’encodeur au décodeur pour préserver les détails spatiaux. Les modules d’attention sont appliqués à chaque bloc du décodeur.

hémisphères) ne sont pas explicitement modélisées. Des architectures à attention globale, comme les *vision transformers*, pourraient mieux capturer ces dépendances, au prix d’un coût de calcul plus élevé. Cette piste n’a pas été explorée dans le cadre de ce projet.

3.3 Prédiction déterministe

3.3.1 Modèle de prédiction et rollout autorégressif

Le modèle de prédiction g_ϕ prend en entrée le champ dense $\hat{X}_t$ et prédit l’état futur $\hat{X}_{t+1}$, correspondant à un décalage de 24 heures (soit 4 pas de temps dans les données ERA5 échantillonnées toutes les 6 heures).

Le modèle de prédiction utilise un second U-Net qui prend en entrée un état complet $\hat{X}_t$ (5 canaux) et produit la prédiction $\hat{X}_{t+1}$ (5 canaux, 24 h plus tard). La baseline de référence est la **persistance** : $\hat{X}_{t+1} = X_t$.

La fonction de perte du modèle déterministe est :

$$\mathcal{L}_{\text{prev}} = \frac{1}{K \cdot H \cdot W} \sum_{k=1}^K \left\| g_\phi(\hat{X}_t)^{(k)} - X_{t+1}^{(k)} \right\|^2 \quad (4)$$

Pour la prédiction à plus long terme, le modèle opère de façon **autoregressive** : il réinjecte ses propres prédictions comme entrée du pas suivant,

$$\hat{X}_{t+n} = g_\phi(\hat{X}_{t+n-1}) = g_\phi^n(\hat{X}_t).$$

Ce mode de *rollout libre* permet d’étendre la prédiction jusqu’à 10 jours ($n = 10$ pas de 24 h), mais l’accumulation d’erreur à chaque pas dégrade progressivement la qualité.

3.3.2 Pr evision   long terme : teacher forcing (push-forward)

Le probl eme de la loss directe. Pour pr evoir   un horizon de n jours, le mod ele est appliqu e n fois de suite (rollout autor egressif). Entra ner directement en minimisant l'erreur au bout de n pas, $\|X_{t+n} - g_\phi^n(X_t)\|_2$, pose trois difficult es fondamentales :

1. Le gradient doit traverser n appels successifs   g_ϕ : le co ut m emoire cro t en $O(n)$ et le gradient peut exploser ou s' vanouir.
2. L'accumulation d'erreur   chaque pas rend la loss peu informative.
3. La distribution des entr ees lors du rollout libre diff ere de celle de l'entra nement (*distributional shift*).

Solution : teacher forcing [WZ89].   chaque pas d'entra nement, avec probabilit e α , l'entr ee du pas suivant est l' etat r eel X_{t+1} plut ot que la pr ediction $\hat{X}_{t+1}$:

$$\tilde{X}_{t+1} = \alpha \cdot X_{t+1} + (1 - \alpha) \cdot \hat{X}_{t+1} \quad (5)$$

Cette strat egie s'inscrit dans le cadre du *push-forward training* r ecemment formalis e par Zhou et Cheng [ZC25].

Algorithm 1 Entra nement avec teacher forcing (push-forward)

Require: Mod ele g_ϕ , taux $\alpha \in [0, 1]$, horizon n

```

1: for chaque batch  $(X_t, X_{t+1}, \dots, X_{t+n})$  do
2:    $\tilde{X} \leftarrow X_t$ 
3:    $\mathcal{L} \leftarrow 0$ 
4:   for  $i = 1$     $n$  do
5:      $\hat{X} \leftarrow g_\phi(\tilde{X})$ 
6:      $\mathcal{L} \leftarrow \mathcal{L} + \|\hat{X} - X_{t+i}\|^2$ 
7:      $\tilde{X} \leftarrow \alpha \cdot X_{t+i} + (1 - \alpha) \cdot \hat{X}$ 
8:   end for
9:   Mettre   jour  $\phi$  par descente de gradient sur  $\mathcal{L}$ 
10: end for
```




FIGURE 4 – Principe du teacher forcing (push-forward). À chaque pas, l'entrée du modèle g_ϕ est soit l'état réel X_{t+1} (avec probabilité α , flèches vertes pointillées), soit la prédiction $\hat{X}_{t+1}$ du pas précédent. Cela stabilise l'entraînement en évitant la dérive cumulative de la distribution des entrées.

3.4 Prédiction probabiliste par interpolant stochastique

3.4.1 Motivation

La prévision déterministe associe à un état initial une sortie unique et ne dit rien de l'incertitude. Or l'atmosphère est chaotique : à +24 h, plusieurs évolutions sont compatibles avec un même état initial, d'autant plus lorsque celui-ci est reconstruit depuis des capteurs éparés. On veut donc un modèle génératif, qui produit non pas une prévision mais un ensemble de prévisions, dont la moyenne sert d'estimation centrale et la dispersion de mesure d'incertitude.

Nous utilisons pour cela un **interpolant stochastique** [ABV25] : on apprend un champ de vitesse v_θ qui transporte l'état initial $x_0 = X_t$ vers l'état futur $x_1 = X_{t+24h}$ le long d'un temps interne $s \in [0, 1]$. Contrairement à un modèle de diffusion, qui part d'un bruit gaussien sans lien avec l'état courant, l'interpolant part de x_0 et construit un chemin continu jusqu'à x_1 . Ce chemin donne trois leviers :

- ses états intermédiaires x_s correspondent à des instants physiques entre t et $t+24 \text{ h}$, donc aux échéances +6, +12, +18 h sans modèle supplémentaire ;
- le modèle s'applique de façon autorégressive pour atteindre des échéances arbitrairement longues avec une résolution arbitraire (le pas est contrôlable) ;
- les états ERA5 intermédiaires, disponibles toutes les 6 h, servent à superviser le chemin et à améliorer le modèle.

3.4.2 Modèle, entraînement et inférence

Le modèle v_θ est un U-Net conditionné par cross-attention sur l'état initial x_0 et par le temps s . Il prend en entrée l'état intermédiaire x_s , l'état initial x_0 et s , et produit un champ de vitesse de la dimension de l'état atmosphérique ($5 \times 32 \times 64$).

À l'entraînement, on dispose d'une paire (état présent x_0 , état futur x_1). On tire $s \sim \mathcal{U}(0, 1)$ et $\varepsilon \sim \mathcal{N}(0, I)$, et on forme l'état intermédiaire :

$$x_s = (1 - s) x_0 + s x_1 + \sigma_{\text{train}} \sqrt{s(1 - s)} \varepsilon. \quad (6)$$

La vitesse cible le long de ce chemin est connue analytiquement, avec $g(s) = \sqrt{s(1 - s)}$:

$$v^\star = \frac{dx_s}{ds} = x_1 - x_0 + \sigma_{\text{train}} \dot{g}(s) \varepsilon, \quad \dot{g}(s) = \frac{1 - 2s}{2\sqrt{s(1 - s)}}. \quad (7)$$

Le réseau apprend à prédire $v^\star$ à partir du seul triplet (x_s, x_0, s) , sans accès à x_1 , et reste donc utilisable à l'inférence où x_1 est inconnu.

La fonction de perte combine quatre termes :

$$\mathcal{L} = \mathcal{L}_v + \lambda_g \mathcal{L}_{\text{grad}} + \lambda_a \mathcal{L}_{\text{anchor}} + \lambda_{ag} \mathcal{L}_{\text{anchor-grad}}. \quad (8)$$

- $\mathcal{L}_v = \|v_\theta(x_s, x_0, s) - v^\star\|^2$ supervise directement la vitesse prédite.
- $\mathcal{L}_{\text{grad}} = \|\nabla(x_0 + v_\theta) - \nabla x_1\|^2$ aligne les gradients spatiaux de la prévision à un pas sur ceux de la cible.
- $\mathcal{L}_{\text{anchor}} = \sum_{k=1}^4 w_k \|\hat{X}_{t+6kh} - X_{t+6kh}\|^2$ contraint les états du rollout intermédiaire sur les ancres ERA5 à +6, 12, 18, 24 h.
- $\mathcal{L}_{\text{anchor-grad}}$ applique la même contrainte sur les gradients de ces états.

Les poids λ_g , λ_a , λ_{ag} , le vecteur w et les hyperparamètres d'entraînement et d'inférence sont donnés en annexe C.

À l'inférence, x_1 est inconnu. On pose $x \leftarrow x_0$ et on intègre le champ appris de $s = 0$ à $s = 1$ par N_{steps} pas d'Euler de taille $\Delta s = 1/N_{\text{steps}}$ (schéma au point milieu) :

$$x \leftarrow x + \Delta s \cdot v_\theta(x, x_0, s) + \sqrt{\Delta s} \sigma_{\text{infer}} \xi, \quad \xi \sim \mathcal{N}(0, I). \quad (9)$$

Sans bruit ($\sigma_{\text{infer}} = 0$), la prévision est unique. Avec bruit, on répète l'intégration N fois depuis le même x_0 pour obtenir un ensemble, dont la moyenne donne la prévision centrale et la dispersion une carte d'incertitude.

Algorithm 2 Entraînement de l’interpolant stochastique

Require: Réseau v_θ , σ_{train} , ε_t , poids $(\lambda_g, \lambda_a, \lambda_{ag})$, w (normalisés)

```
1: for chaque batch  $(x_0, \{X_{t+6kh}\}_{k=1}^4)$ , avec  $x_1 = X_{t+24h}$  do  
    // terme de vitesse, à un instant aléatoire  
2:    $s \sim \mathcal{U}(\varepsilon_t, 1 - \varepsilon_t)$ ,  $\varepsilon \sim \mathcal{N}(0, I)$   
3:    $x_s \leftarrow (1 - s)x_0 + sx_1 + \sigma_{\text{train}}\sqrt{s(1-s)}\varepsilon$   
4:    $v^* \leftarrow x_1 - x_0 + \sigma_{\text{train}}\dot{g}(s)\varepsilon$   
5:    $\hat{v} \leftarrow v_\theta(x_s, x_0, s)$   
6:    $\mathcal{L}_v \leftarrow \|\hat{v} - v^*\|^2$ ,  $\mathcal{L}_{\text{grad}} \leftarrow \|\nabla(x_0 + \hat{v}) - \nabla x_1\|^2$   
    // termes d’ancrage : rollout d’Euler à 4 pas,  $\Delta s = 1/4$ , point milieu  
7:    $x \leftarrow x_0$   
8:   for  $k = 1$  à  $4$  do  
9:      $x \leftarrow x + \frac{1}{4}v_\theta(x, x_0, \frac{k-1/2}{4})$   
10:     $\hat{X}_{t+6kh} \leftarrow x$   
11:  end for  
12:   $\mathcal{L}_{\text{anchor}} \leftarrow \sum_{k=1}^4 w_k \|\hat{X}_{t+6kh} - X_{t+6kh}\|^2$   
13:   $\mathcal{L}_{\text{anchor-grad}} \leftarrow \sum_{k=1}^4 w_k \|\nabla \hat{X}_{t+6kh} - \nabla X_{t+6kh}\|^2$   
14:   $\mathcal{L} \leftarrow \mathcal{L}_v + \lambda_g \mathcal{L}_{\text{grad}} + \lambda_a \mathcal{L}_{\text{anchor}} + \lambda_{ag} \mathcal{L}_{\text{anchor-grad}}$   
15:  mise à jour de  $\theta$  (AdamW, clip de gradient à 1), puis de la moyenne EMA  
16: end for
```

3.5 Évaluation de la chaîne complète

La chaîne complète est évaluée de bout en bout :

$$\text{Observations éparées} \xrightarrow{f_\theta} \text{Champ reconstruit } \hat{X}_t \xrightarrow{g_\phi} \text{Prévision } \hat{X}_{t+1} \quad (10)$$

Cette évaluation *end-to-end* permet de quantifier l’erreur cumulée des deux étapes et d’identifier laquelle limite le plus la performance globale.

4 Résultats

4.1 Métriques d’évaluation

La qualité des résultats est mesurée par trois indicateurs complémentaires :

- **NRMSE** (erreur quadratique moyenne normalisée) : mesure l’écart moyen entre prédiction et réalité, normalisé par l’écart-type du champ sur le jeu d’entraînement. Plus la valeur est basse, meilleure est la reconstruction.
- **ACC** (corrélacion de l’anomalie) : mesure la capacité du modèle à reproduire les structures spatiales du champ, en comparant les anomalies (écarts à la climatologie, définie comme la moyenne temporelle sur le split d’entraînement, par point de grille et par variable). Une valeur proche de 1 indique une bonne reproduction des structures atmosphériques. En prévision opérationnelle, un ACC inférieur à 0,6 est généralement considéré sous le seuil d’utilité.
- **SSIM** (indice de similarité structurelle) : métrique issue du traitement d’images, sensible à la préservation des contrastes locaux et des structures fines. Varie entre 0 et 1.

4.2 Reconstruction

4.2.1 Résultats à 10 % de capteurs

Le tableau 1 présente les métriques de reconstruction par variable sur le jeu de test, à 10 % de points observés, pour notre modèle et pour le CNN de Fukami et al. [Fuk+21] réimplémenté

sur les mêmes données.

TABLE 1 – Métriques de reconstruction à 10 % de capteurs : notre modèle (U-Net++ avec CBAM) comparé au CNN de Fukami et al. [Fuk+21]. Les flèches indiquent le sens d’amélioration. La RMSE est exprimée dans les unités physiques de chaque variable.

Var.	Notre modèle				Fukami (baseline)			
	NRMSE↓	RMSE	ACC↑	SSIM↑	NRMSE↓	RMSE	ACC↑	SSIM↑
z_{850}	0.151	214.8 m²s⁻²	0.933	0.935	0.212	300.9 m ² s ⁻²	0.859	0.886
q_{850}	0.257	1.1 × 10⁻³ kg/kg	0.810	0.813	0.294	1.2 × 10 ⁻³ kg/kg	0.654	0.771
T_{2m}	0.113	2.42 K	0.915	0.953	0.182	3.85 K	0.690	0.927
u_{10}	0.388	1.89 m/s	0.853	0.746	0.486	2.37 m/s	0.743	0.616
v_{10}	0.483	2.00 m/s	0.844	0.657	0.588	2.44 m/s	0.745	0.502
Moy.	0.278	—	0.871	0.821	0.352	—	0.738	0.740

Analyse par variable. La hiérarchie de difficulté entre variables s’explique par leur structure spatiale. Le géopotentiel (z_{850}) et la température (T_{2m}) présentent des champs spatialement lisses, dominés par des structures de grande échelle (gradients pôle-équateur, masses d’air continentales). À 10 % de capteurs, ces structures sont déjà partiellement capturées par l’interpolation de Voronoï, et le réseau n’a qu’à affiner les transitions. Les NRMSE correspondantes sont faibles (0,151 et 0,113) et les ACC élevées (0,933 et 0,915).

À l’inverse, les composantes de vent (u_{10} , v_{10}) varient sur des échelles spatiales plus fines et de manière plus turbulente. La mosaïque de Voronoï y est une approximation beaucoup plus grossière, et le réseau doit reconstruire des structures que l’entrée ne contient pas. v_{10} est la variable la plus difficile (NRMSE = 0,483), ce qui est cohérent avec la variabilité spatiale élevée du vent méridional aux latitudes extratropicales.

L’humidité spécifique (q_{850}) se situe à un niveau intermédiaire. Bien que physiquement couplée à la température via la relation de Clausius-Clapeyron, sa distribution spatiale est plus hétérogène, avec des gradients marqués entre régions tropicales humides et zones arides.

Comparaison avec le baseline. Notre modèle surpasse le CNN de Fukami sur l’ensemble des variables et des métriques. Le gain relatif en NRMSE moyen est de −21 % (0,278 contre 0,352), et le gain en ACC moyen est de +18 % (0,871 contre 0,738). Le gain est particulièrement marqué pour T_{2m} (ACC : 0,915 contre 0,690, soit +33 %), ce qui confirme que l’architecture multi-échelle capte mieux les structures de grande taille que le CNN séquentiel. Toutes les variables dépassent le seuil de prévision utile défini par l’OMM (ACC > 0,6).

4.2.2 Résultats visuels

La figure 5 illustre la reconstruction pour les cinq variables sur un exemple du jeu de test. Pour chaque variable, on compare le champ de référence ERA5, les observations éparées, l’interpolation de Voronoï brute et la reconstruction produite par le réseau. Le réseau restitue les structures principales du champ (gradients de température, patterns de vent) et élimine les artefacts en mosaïque introduits par la tessellation de Voronoï. Les erreurs résiduelles sont concentrées aux frontières entre masses d’air et dans les zones de vent turbulent aux latitudes extratropicales.

4.2.3 Robustesse au taux d’observation

Le modèle, entraîné uniquement à 10 % de capteurs, est évalué sans ré-entraînement sur des taux d’observation allant de 5 % à 50 %. La figure 6 montre que les trois métriques s’améliorent de manière monotone avec le taux d’observation. Cette monotonie confirme que le réseau exploite effectivement l’information supplémentaire apportée par des capteurs plus denses, sans être limité par son architecture. Le modèle généralise ainsi à des configurations de capteurs qu’il n’a




FIGURE 5 – Reconstruction à 10% de capteurs pour les cinq variables atmosphériques. De gauche à droite : champ de référence ERA5 (GT), observations éparses (Obs 10 %), interpolation de Voronoï, reconstruction par le réseau (Pred), et carte d'erreur absolue.

jamais vues à l'entraînement, ce qui est un résultat important pour une éventuelle application opérationnelle où le nombre de capteurs disponibles varie dans le temps.




FIGURE 6 – Évolution des métriques de reconstruction (NRMSE, ACC, SSIM) en fonction du taux d'observation, moyennées sur les cinq variables. Le modèle est entraîné à 10 % et évalué sans ré-entraînement sur l'ensemble des densités.

4.3 Pr vision d terministe   24 heures

Le mod le de pr vision d terministe est  valu  dans deux configurations : depuis un champ dense complet (entr e ERA5 sans perte d'information) et depuis un champ reconstruit   partir de 10 % de capteurs. La comparaison entre ces deux configurations permet d'isoler la d gradation introduite par l' tape de reconstruction.

4.3.1 R sultats depuis un champ dense

Le tableau 3 compare la pr vision   +24 h   la baseline de persistance (pr dire que l'atmosph re reste inchang e). Le mod le surpasse la persistance sur l'ensemble des variables, avec un gain moyen de -37% en NRMSE (0,289 contre 0,456). Le gain est particuli rement marqu  pour les composantes de vent : v_{10} passe de 0,901   0,521 en NRMSE (-42%), confirmant que ces variables, tr s mal pr dites par la persistance, b n ficient le plus d'un mod le appris. T_{2m} reste la variable la mieux pr vue ($ACC = 0,961$), ce qui est coh rent avec la forte autocorr lation temporelle de la temp rature   +24 h (cycle diurne).

TABLE 2 – Pr vision d terministe   +24 h depuis un champ dense, compar e   la persistance.

Var.	Pr�vision +24h			Persistance		
	NRMSE�	ACC�	SSIM�	NRMSE�	ACC�	SSIM�
z_{850}	0.206	0.896	0.939	0.312	0.728	0.847
q_{850}	0.184	0.915	0.904	0.300	0.740	0.736
T_{2m}	0.079	0.968	0.978	0.126	0.900	0.941
u_{10}	0.411	0.861	0.766	0.644	0.599	0.547
v_{10}	0.511	0.848	0.675	0.901	0.434	0.352
Moy.	0.278	0.898	0.852	0.456	0.680	0.685

4.3.2 Impact de la reconstruction sur la pr vision

Lorsque le mod le de pr vision re oit en entr e un champ reconstruit plut t qu'un champ dense, les performances se d gradent. En moyenne, le NRMSE augmente de $+33\%$ et l'ACC diminue de -12% . Cette d gradation n'est pas uniforme : T_{2m} reste la variable la mieux pr vue dans les deux configurations ($ACC = 0,961$ sur champ dense, $0,909$ sur champ reconstruit), tandis que les composantes de vent sont les plus affect es. v_{10} passe de 0,521   0,659 en NRMSE ($+29\%$), et q_{850} pr sente la plus forte baisse relative d'ACC (-13%). Ce r sultat est coh rent avec l'analyse de la section reconstruction : les variables les plus difficiles   reconstruire sont aussi celles dont la pr vision souffre le plus du passage par la reconstruction.

  titre de comparaison, si les erreurs de reconstruction et de pr vision s'accumulaient de mani re ind pendante, on attendrait une NRMSE de l'ordre de $\sqrt{0,278^2 + 0,278^2} \approx 0,393$. Le pipeline end-to-end obtient une NRMSE de 0,370, inf rieure   cette estimation. Cela sugg re que l'apprentissage conjoint limite partiellement l'accumulation d'erreurs entre les deux  tapes.

TABLE 3 – Pr vision d terministe   +24 h : comparaison depuis un champ dense (entr e ERA5 compl te) et depuis un champ reconstruit   10 % de capteurs.

Var.	Depuis champ dense				Depuis champ reconstruit			
	NRMSE�	RMSE	ACC�	SSIM�	NRMSE�	RMSE	ACC�	SSIM�
z_{850}	0.206	293.2 m ² s ⁻²	0.896	0.939	0.268	380.5 m ² s ⁻²	0.802	0.880
q_{850}	0.184	0.0007 kg/kg	0.915	0.904	0.272	0.0011 kg/kg	0.793	0.793
T_{2m}	0.079	1.69 K	0.968	0.978	0.126	2.69 K	0.909	0.949
u_{10}	0.411	2.00 m/s	0.861	0.766	0.528	2.57 m/s	0.732	0.609
v_{10}	0.511	2.12 m/s	0.848	0.675	0.659	2.73 m/s	0.704	0.478
Moy.	0.278	—	0.898	0.852	0.370	—	0.788	0.742

4.3.3 Prédiction autoregressive sur 7 jours

En mode rollout, le modèle réinjecte ses propres prédictions pour étendre la prévision au-delà de 24 h. La figure 7 montre l'évolution de la NRMSE moyenne sur 7 jours. Le modèle reste systématiquement en dessous de la persistance, confirmant son utilité même à horizons longs. La croissance de l'erreur est sous-linéaire, sans divergence explosive, ce qui valide la stabilisation apportée par le teacher forcing lors de l'entraînement.




FIGURE 7 – NRMSE moyenne sur 7 jours de prévision autoregressive, comparée à la persistance depuis le champ reconstruit.

4.3.4 Résultats visuels

La figure 8 illustre la chaîne complète sur un exemple du jeu de test : à partir des observations éparées à t , le réseau reconstruit le champ dense, puis le modèle de prévision produit l'état à $t + 4$ jours. Les structures principales (gradients de température, zones de vent fort) sont correctement préservées, tandis que les erreurs se concentrent sur les détails fins du vent aux latitudes extratropicales.




FIGURE 8 – Chaîne complète reconstruction + prévision à $t + 4$ jours pour les cinq variables. Pour chaque variable : champ réel à t (col. 1), masque d'observation à t (col. 2), reconstruction à t (col. 3), prévision à $t + 4$ (col. 4), vérité terrain à $t + 4$ (col. 5).

4.4 Prédiction probabiliste par interpolant stochastique

4.4.1 Protocole et entraînement

Le modèle d'interpolant stochastique est entraîné sur ERA5/WeatherBench2 à résolution 64×32 , avec la normalisation calculée exclusivement sur le jeu d'entraînement. On retient le meilleur checkpoint (poids EMA) au sens de la perte de validation. L'entraînement dure **10,43 minutes**.




FIGURE 9 – Pertes d’entraînement (bleu) et de validation (orange). Le meilleur checkpoint (poids EMA) est atteint à l’époque 19 (perte de validation $\approx 0,295$). Aucun sur-apprentissage visible.

4.4.2 Prédiction dense à +24 h

Le tableau 4 compare le modèle (5 pas d’Euler, inférence déterministe $\sigma_{\text{infer}} = 0$) à la persistance. La référence est ici la **persistance dense** ($\hat{X}_{t+24h} = X_t$ sur champ complet), à distinguer de la persistance sur champ reconstruit employée pour la prévision déterministe.

TABLE 4 – Prédiction dense +24 h : interpolant stochastique (5 pas d’Euler, déterministe) versus persistance dense.

Var.	Persistance dense		Interpolant stochastique			
	NRMSE↓	ACC↑	RMSE	NRMSE↓	ACC↑	SSIM↑
z_{850}	0.3033	0.7582	$308.6 \text{ m}^2\text{s}^{-2}$	0.2172	0.8809	0.9245
q_{850}	0.2893	0.8007	$8 \times 10^{-4} \text{ kg/kg}$	0.2022	0.8962	0.8784
T_{2m}	0.0918	0.9550	1.76 K	0.0824	0.9642	0.9745
u_{10}	0.6742	0.6203	2.16 m/s	0.4436	0.8320	0.7397
v_{10}	0.9541	0.4499	2.33 m/s	0.5621	0.8096	0.6293
Moy.	0.4625	0.7168	—	0.3015	0.8766	0.8293

Le modèle réduit la NRMSE moyenne de 0,161 par rapport à la persistance dense, soit une amélioration relative de **34,8 %**. Le gain est surtout porté par les composantes de vent (u_{10} , v_{10}), pour lesquelles la persistance est très mauvaise ($\text{NRMSE} > 0,67$). À l’inverse, T_{2m} est déjà bien prédite par la persistance : à +24 h, l’état à t est proche de l’état à la même heure le lendemain (cycle diurne), ce qui laisse peu de marge.

4.4.3 Choix du schéma d’inférence

Le tableau 5 balaie le nombre de pas d’Euler $N_{\text{steps}} \in \{5, 10, 20, 30, 40\}$ et le nombre d’échantillons $N \in \{1, 5, 10, 20, 30\}$, à $\sigma_{\text{infer}} = 0,01$.

TABLE 5 – Balayage : NRMSE moyenne de la prévision +24 h selon le nombre de pas d’Euler et d’échantillons ($\sigma_{\text{infer}} = 0,01$).

N_{steps}	N_{samples}	NRMSE↓	ACC↑	SSIM↑
5	1	0.3017	0.8763	0.8288
5	5	0.3015	0.8765	0.8292
5	10	0.3015	0.8766	0.8292
5	30	0.3015	0.8766	0.8292
10	30	0.3060	0.8716	0.8242
20	30	0.3083	0.8691	0.8217
30	30	0.3090	0.8683	0.8208
40	30	0.3094	0.8679	0.8204

Deux constats. D’abord, **5 pas d’Euler suffisent** : le champ de vitesse appris est assez régulier pour que l’intégration converge vite, et augmenter le nombre de pas dégrade même légèrement les métriques, sans doute par accumulation du bruit stochastique. Ensuite, **l’ensemble sature immédiatement** : passer de 1 à 5 échantillons ne gagne que 0,0002 en NRMSE, et plus rien au-delà de 10. C’est le signe d’une dispersion stochastique très faible à $\sigma_{\text{infer}} = 0,01$, ce qui justifie le choix de l’inférence déterministe pour le tableau 4.




FIGURE 10 – NRMSE selon le nombre d’échantillons (échelle log), par nombre de pas d’Euler. La courbe à 5 pas est optimale ; au-delà de 5 échantillons, le gain est inférieur à 5×10^{-4} .

4.4.4 Ensemble et incertitude

La figure 11 montre, pour un cas test, la vérité ERA5, la moyenne d’ensemble, l’erreur absolue et la dispersion par point de grille obtenue en inférence stochastique. La dispersion se concentre qualitativement sur les zones de forte erreur, en particulier sur le vent aux latitudes extratropicales, ce qui est le comportement attendu.




FIGURE 11 – Ensemble stochastique ($\sigma_{\text{infer}} = 0,01$) pour T_{2m} (haut) et la vitesse du vent (bas) : vérité ERA5, moyenne d'ensemble, erreur absolue, dispersion. Les zones de forte dispersion coïncident avec les zones d'erreur élevée.

4.4.5 Stabilité en rollout multi-journalier

On évalue la stabilité en **rollout** : la prévision à $t + 24$ h est réinjectée comme condition initiale pour $t + 48$ h, et ainsi de suite jusqu'à 10 jours.




FIGURE 12 – NRMSE en rollout libre sur 10 jours (5 pas d’Euler). La NRMSE passe de 0,30 à +24 h à 0,65 à +10 jours : croissance sous-linéaire, sans divergence.

5 Analyse critique

5.1 Difficultés

Trois difficultés majeures ont structuré notre travail :

Difficulté informatique : volume des données. Le jeu ERA5 complet dépasse la capacité mémoire de nos machines, nous contraignant à sous-échantillonner temporellement.

Difficulté scientifique : accumulation d’erreur dans la chaîne. Le couplage reconstruction → prévision introduit une erreur composée.

Difficulté d’évaluation : absence de benchmark adapté. WeatherBench 2 ne fournit pas de référence à notre résolution (64×32) pour la tâche de reconstruction depuis des capteurs épars.

5.2 Critique des choix méthodologiques

Le prétraitement par Voronoï. La tessellation de Voronoï transforme un ensemble de mesures éparses en une image structurée, exploitable par un réseau convolutif. Ce choix, hérité de Fukami et al. [Fuk+21], est motivé par sa simplicité : il ne nécessite aucun paramètre et se calcule en temps quasi-linéaire via un arbre de recherche spatiale. En revanche, il introduit des discontinuités artificielles aux frontières entre cellules, que le réseau doit ensuite lisser. Le choix du plus proche voisin ($k = 1$) plutôt qu’une moyenne pondérée sur $k > 1$ voisins est délibéré : une interpolation par k -NN lisserait l’entrée avant même que le réseau n’intervienne, ce qui reviendrait à pré-décider du niveau de détail à reconstruire. En laissant l’entrée volontairement grossière, on délègue entièrement la reconstruction au réseau.

Des alternatives existent néanmoins : l’interpolation bilinéaire produirait des entrées plus lisses mais perdrait la localisation exacte des capteurs ; le krigeage exploiterait la structure de covariance spatiale du champ, mais nécessiterait d’estimer un variogramme par variable ; un *graph neural network* [BWW22] opérant directement sur le graphe irrégulier des capteurs éviterait toute interpolation préalable, au prix d’une complexité d’implémentation supérieure. Ces pistes n’ont pas été explorées dans le cadre de ce projet.

L’architecture U-Net est-elle adaptée à cette résolution ? À une résolution de 64×32 , un U-Net à 3 niveaux de compression réduit l’image à 8×4 au niveau le plus bas. Les convolutions locales ne modélisent pas explicitement les corrélations à longue portée : un transformer ou un réseau avec des couches d’attention globale pourrait mieux capturer ces dépendances.

Limites des données et du protocole. Notre sous-ensemble de 4 000 pas de temps ne couvre qu’environ trois ans (1959–1961), ce qui limite la diversité des régimes atmosphériques vus à l’entraînement. Un passage à l’échelle sur l’ensemble ERA5 (1959–2022) impliquerait un découpage où le jeu de test couvrirait une période récente (typiquement 2013–2022), marquée par un réchauffement climatique plus prononcé que la moyenne d’entraînement. Ce *dataset shift* climatique affecterait principalement les variables sensibles au réchauffement (T_{2m} , q_{850}) et devrait être pris en compte dans une évaluation à plus grande échelle. Par ailleurs, le masque de capteurs est tiré uniformément sur la grille, alors qu’en pratique les stations d’observation sont concentrées sur les terres habitées. Un masque réaliste (par exemple calqué sur le réseau SYNOP) constituerait un test de robustesse plus exigeant.

5.3 Positionnement des résultats

Reconstruction. À 10 % de capteurs, le modèle atteint un ACC moyen de 0,871 et un NRMSE moyen de 0,278, surpassant le CNN de Fukami et al. sur l’ensemble des variables. Les variables à structure lisse (z_{850} , T_{2m}) sont reconstruites avec un ACC supérieur à 0,91, tandis que les composantes de vent, plus turbulentes, restent les plus difficiles (v_{10} : NRMSE = 0,483). Le modèle généralise à des taux d’observation de 5 % à 50 % sans ré-entraînement.

Prévision probabiliste. L’interpolant stochastique réduit la NRMSE de 34,8 % par rapport à la persistance et génère des cartes d’incertitude spatiale. Contrairement à un modèle de diffusion, qui part d’un bruit gaussien sans lien avec l’état courant et ne fournit aucun chemin de X_t à X_{t+24h} , l’interpolant produit un modèle génératif capable de simuler prédire plusieurs chemins futurs et donne accès aux échéances intermédiaires et au delà de l’échéance +24h.

Comparaison externe. À titre indicatif, GraphCast [Lam+23] atteint une NRMSE de l’ordre de 0,1 à +24 h sur T_{2m} à résolution $0,25^\circ$, entraîné sur 39 ans de données ERA5. Notre modèle, à résolution $5,6^\circ$ et sur un sous-ensemble réduit, atteint une NRMSE de 0,0824 sur T_{2m} (0,3015 en moyenne sur les cinq variables). L’écart reflète principalement la différence de résolution et de volume de données, et constitue lui-même une information scientifique : il quantifie le coût de la résolution réduite.

5.4 Apports par rapport à l’état de l’art

Notre travail se distingue du cadre de Fukami et al. [Fuk+21] sur plusieurs plans. Sur le volet reconstruction, nous remplaçons le CNN séquentiel par un U-Net++ enrichi de modules d’attention CBAM, de blocs résiduels et de dropout, et nous introduisons une fonction de coût composite intégrant une pénalité de gradient spatial. Nous étendons par ailleurs l’approche à 5 variables atmosphériques simultanées, alors que Fukami et al. traitent une seule variable à la fois. Sur le volet prévision, nous couplons la reconstruction avec un modèle de prévision déterministe par teacher forcing et un modèle de prévision probabiliste par interpolants stochastiques [ABV25], constituant ainsi une chaîne complète capteurs épars $\rightarrow$ reconstruction $\rightarrow$ prévision. L’ensemble est évalué sur des données réelles ERA5 selon le protocole WeatherBench 2 [Ras+24].

6 Conclusion et perspectives

Ce projet implémente une chaîne complète de reconstruction et de prévision de champs atmosphériques depuis des mesures éparées, en s'appuyant sur l'approche de Fukami et al. [Fuk+21] et le protocole WeatherBench 2 [Ras+24].

La reconstruction par U-Net++ depuis une tessellation de Voronoï est opérationnelle sur cinq variables ERA5 simultanées. La prévision probabiliste par interpolant stochastique [ABV25] bat la persistance de $-34,8\%$ en NRMSE à $+24$ h tout en fournissant des cartes d'incertitude spatiale via l'inférence d'ensemble. Ce modèle génératif se distingue par sa légèreté : il s'entraîne en moins de 11 minutes sur environ 4 000 états ERA5 à résolution 64×32 et converge en seulement 5 pas d'Euler à l'inférence.

Perspectives. Plusieurs pistes d'amélioration se dégagent :

- **Calibration de l'incertitude** : explorer des valeurs plus élevées de σ_{infer} dans l'inférence stochastique pour augmenter la diversité d'ensemble au détriment de la NRMSE ponctuelle.
- **Roll-out autorégressif probabiliste** : coupler l'interpolant stochastique avec un mécanisme de teacher forcing pour les prévisions multi-jours.
- **Transport optimal exact** : utiliser l'IPF ou des méthodes variationnelles pour apprendre le transport optimal au sens du pont de Schrödinger, au lieu d'une régression de vitesse directe.
- **Exploration architecturale** : tester des vision transformers ou des architectures hybrides CNN-transformer pour mieux capturer les corrélations à longue portée.

Apport au CEREA et perspectives industrielles. Ce travail fournit au CEREA une preuve de concept d'un pipeline complet capteurs éparés $\rightarrow$ reconstruction $\rightarrow$ prévision, évalué sur données réelles ERA5 selon le protocole WeatherBench 2. Sur le plan scientifique, il démontre que le couplage Voronoï + U-Net++ permet une reconstruction exploitable à partir de 10 % d'observations, et que l'interpolant stochastique produit des cartes d'incertitude spatiale cohérentes en moins de 11 minutes d'entraînement. Sur le plan industriel, ce type de pipeline ouvre des pistes concrètes : initialiser un modèle de prévision numérique (NWP) depuis un réseau de capteurs incomplet, exploiter des données de bouées océaniques ou de capteurs IoT déployés de façon irrégulière, ou encore fournir des prévisions d'ensemble pour la gestion des risques climatiques (énergie, agriculture, assurance). Les limites actuelles, résolution 64×32 , masque uniforme, sous-échantillonnage temporel, définissent précisément les prochaines étapes prévues.

Organisation du projet

Répartition des tâches

La mise en place du pipeline de données et du prétraitement Voronoï a été réalisée conjointement. Le développement des architectures et l'analyse des résultats ont fait l'objet d'une répartition par tâches : reconstruction (architecture, entraînement, évaluation), prévision déterministe, prévision probabiliste par interpolant stochastique, et rédaction. Les expériences sont conduites sur un notebook Jupyter partagé et des scripts Python, via un dépôt GitHub commun.

Réunions avec le tuteur

Sept réunions ont eu lieu depuis le début du projet (18/02, 25/02, 18/03, 01/04, 15/04, 06/05, 20/05), à un rythme d'environ deux semaines. Ces échanges ont permis de valider les orientations méthodologiques, d'affiner les choix d'architecture et de prioriser les expériences.

Références

- [ABV25] M. S. ALBERGO, N. M. BOFFI et E. VANDEN-EIJNDEN. « Stochastic Interpolants : A Unifying Framework for Flows and Diffusions ». In : *Journal of Machine Learning Research* 26.188 (2025), p. 1-65. arXiv : [2303.08797](https://arxiv.org/abs/2303.08797).
- [Bi+23] K. BI, L. XIE, H. ZHANG, X. CHEN, X. GU et Q. TIAN. « Accurate medium-range global weather forecasting with 3D neural networks ». In : *Nature* 619 (2023), p. 533-538.
- [BWW22] J. BRANDSTETTER, D. E. WORRALL et M. WELLING. « Message Passing Neural PDE Solvers ». In : *International Conference on Learning Representations (ICLR)*. 2022. arXiv : [2202.03376](https://arxiv.org/abs/2202.03376).
- [Fuk+21] K. FUKAMI, R. MAULIK, N. RAMACHANDRA, K. FUKAGATA et K. TAIRA. « Global field reconstruction from sparse sensors with Voronoi tessellation-assisted deep learning ». In : *Nature Machine Intelligence* 3.11 (2021), p. 945-951.
- [Lam+23] R. LAM, A. SANCHEZ-GONZALEZ, M. WILLSON, P. WIRNSBERGER, M. FORTUNATO, F. ALET, S. RAVURI, T. EWALDS, Z. EATON-ROSEN, W. HU, A. MEROSE, S. HOYER, G. HOLLAND, O. VINYALS, J. STOTT, A. PRITZEL, S. MOHAMED et P. BATTAGLIA. « GraphCast : Learning skillful medium-range global weather forecasting ». In : *Science* 382 (2023), p. 1416-1421.
- [Ras+24] S. RASP, S. HOYER, A. MEROSE, I. LANGMORE, P. BATTAGLIA, T. RUSSELL, A. SANCHEZ-GONZALEZ, V. YANG, R. CARVER, S. AGRAWAL, M. CHANTRY, Z. BEN BOUALLEGUE, P. DUEBEN, C. BROMBERG, J. SISK, L. BARRINGTON, A. BELL et F. SHA. « WeatherBench 2 : A benchmark for the next generation of data-driven global weather models ». In : *Journal of Advances in Modeling Earth Systems* 16.6 (2024), e2023MS004019.
- [RFB15] O. RONNEBERGER, P. FISCHER et T. BROX. « U-Net : Convolutional Networks for Biomedical Image Segmentation ». In : *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2015.
- [RHM+24] S. RASP, S. HOYER, A. MEROSE et al. *WeatherBench 2 — Data Guide*. <https://weatherbench2.readthedocs.io/en/latest/data-guide.html>. Consulté en mai 2026. 2024.
- [Woo+18] S. WOO, J. PARK, J.-Y. LEE et I. S. KWEON. « CBAM : Convolutional Block Attention Module ». In : *European Conference on Computer Vision (ECCV)*. 2018.
- [WZ89] R. J. WILLIAMS et D. ZIPSER. « A Learning Algorithm for Continually Running Fully Recurrent Neural Networks ». In : *Neural Computation* 1.2 (1989), p. 270-280.
- [ZC25] H. ZHOU et S. CHENG. « Improving long-term autoregressive spatiotemporal predictions : A proof of concept with fluid dynamics ». In : *Computer Methods in Applied Mechanics and Engineering* 447 (2025), p. 118332.
- [Zho+18] Z. ZHOU, M. M. RAHMAN SIDDIQUEE, N. TAJBAKHSI et J. LIANG. « UNet++ : A Nested U-Net Architecture for Medical Image Segmentation ». In : *Deep Learning in Medical Image Analysis (DLMIA)*. 2018.

A Détails du réseau de reconstruction

A.1 Table d’architecture

Le tableau 6 détaille la résolution spatiale, le nombre de canaux et les modules utilisés à chaque niveau du réseau de reconstruction.

Niveau	Résolution	Canaux	Skip connections	Module
Entrée	32×64	15	—	—
Encodeur 1	32×64	64	→ Décodeur 1	ConvBlock + CBAM
Encodeur 2	16×32	128	→ Décodeur 2	ConvBlock + CBAM
Encodeur 3	8×16	256	→ Décodeur 3	ConvBlock + CBAM
Bottleneck	4×8	512	—	ConvBlock + Dropout(0.3)
Décodeur 3	8×16	256	← Encodeur 3	ConvTranspose + CBAM
Décodeur 2	16×32	128	← Encodeur 2	ConvTranspose + CBAM
Décodeur 1	32×64	64	← Encodeur 1	ConvTranspose + CBAM
Sortie	32×64	5	—	Conv 1×1

TABLE 6 – Architecture du réseau de reconstruction. Le modèle comporte 8,3 millions de paramètres en configuration de base et 33,3 millions en configuration étendue.

A.2 Skip connections et connexions denses

Skip connections classiques. Dans un U-Net standard, chaque niveau du décodeur reçoit les features remontées par les couches inférieures et les features du niveau symétrique de l’encodeur, concaténées en canaux :

$$d_i = \text{Conv}([u_i, e_i]) \quad (11)$$

où e_i désigne les features de l’encodeur au niveau i , u_i les features remontées par le décodeur, et $[\cdot, \cdot]$ la concaténation en canaux. Ce mécanisme permet de récupérer les détails fins perdus lors de la compression (pooling), de mieux localiser les structures spatiales et de stabiliser l’apprentissage du décodeur.

Connexions denses (U-Net++). Dans notre architecture, le décodeur reçoit également des informations provenant d’autres niveaux de résolution. Par exemple :

$$d_2 = \text{Conv}([u_2, e_2, \text{pool}(e_1)]) \quad (12)$$

$$d_1 = \text{Conv}([u_1, e_1, \text{up}(e_2)]) \quad (13)$$

Cette densification des connexions est particulièrement utile dans notre contexte : les champs atmosphériques contiennent simultanément des structures locales (fronts, gradients) et des structures à grande échelle (masses d’air, anticyclones), et l’entrée Voronoï est une approximation grossière que le réseau doit affiner à toutes les échelles. Les connexions denses réduisent la dépendance au bottleneck en permettant aux informations de circuler par plusieurs chemins à travers le réseau.

A.3 Module d’attention CBAM

Soit $\mathbf{F} \in \mathbb{R}^{C \times H \times W}$ le tenseur de features en sortie d’un bloc convolutif. Le module CBAM applique deux étapes d’attention séquentielles.

1. Attention par canal. On résume chaque canal c par deux statistiques globales :

$$\mathbf{z}_c^{\text{avg}} = \frac{1}{HW} \sum_{i,j} F_{c,i,j}, \quad \mathbf{z}_c^{\text{max}} = \max_{i,j} F_{c,i,j} \quad (14)$$

On obtient deux vecteurs $\mathbf{z}_c^{\text{avg}}, \mathbf{z}_c^{\text{max}} \in \mathbb{R}^C$. Chacun passe dans un MLP partagé à une couche cachée avec un ratio de réduction r :

$$\text{MLP}(\mathbf{z}) = \mathbf{W}_1 \sigma(\mathbf{W}_0 \mathbf{z}), \quad \mathbf{W}_0 \in \mathbb{R}^{C/r \times C}, \mathbf{W}_1 \in \mathbb{R}^{C \times C/r}, \sigma = \text{ReLU} \quad (15)$$

Le masque canal est obtenu par combinaison et activation sigmoïde :

$$\mathbf{M}_c = \sigma_s(\text{MLP}(\mathbf{z}_c^{\text{avg}}) + \text{MLP}(\mathbf{z}_c^{\text{max}})) \in [0, 1]^C \quad (16)$$

On applique : $\mathbf{F}' = \mathbf{M}_c \otimes \mathbf{F}$ (produit canal par canal). Chaque canal est ainsi pondéré selon son utilité pour la tâche en cours.

2. Attention spatiale. On résume les C canaux en chaque position (i, j) :

$$\mathbf{S}_{i,j}^{\text{avg}} = \frac{1}{C} \sum_c F'_{c,i,j}, \quad \mathbf{S}_{i,j}^{\text{max}} = \max_c F'_{c,i,j} \quad (17)$$

On concatène pour obtenir un tenseur $[\mathbf{S}^{\text{avg}}; \mathbf{S}^{\text{max}}] \in \mathbb{R}^{2 \times H \times W}$. Le masque spatial est produit par une convolution 7×7 :

$$\mathbf{M}_s = \sigma_s(f^{7 \times 7}([\mathbf{S}^{\text{avg}}; \mathbf{S}^{\text{max}}])) \in [0, 1]^{H \times W} \quad (18)$$

On applique : $\mathbf{F}'' = \mathbf{M}_s \otimes \mathbf{F}'$ (produit pixel par pixel). Chaque position spatiale est ainsi pondérée selon la difficulté de reconstruction locale.

Pipeline complet. Les deux étapes sont appliquées séquentiellement :

$$\mathbf{F} \xrightarrow{\text{canal}} \mathbf{F}' = \mathbf{M}_c \otimes \mathbf{F} \xrightarrow{\text{spatial}} \mathbf{F}'' = \mathbf{M}_s \otimes \mathbf{F}' \quad (19)$$

Les dimensions de $\mathbf{F}''$ sont identiques à celles de $\mathbf{F}$: le module est transparent pour l'architecture et peut être inséré après n'importe quel bloc convolutif.

Surcoût en paramètres. Pour C canaux et un ratio de réduction $r = 16$, le MLP ajoute $2 \times C \times C/r$ paramètres et la convolution spatiale en ajoute $2 \times 7^2 = 98$. Ce surcoût est négligeable par rapport au nombre total de paramètres du réseau.

B Métriques d'évaluation

La qualité des reconstructions et des prévisions est mesurée par trois métriques complémentaires, conformément au protocole WeatherBench 2 [Ras+24].

B.1 NRMSE (Normalized Root Mean Square Error)

L'erreur quadratique moyenne normalisée mesure l'écart moyen entre le champ prédit $\hat{x}$ et le champ de référence x , rapporté à la variabilité naturelle du champ :

$$\text{NRMSE} = \frac{\sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{x}_i - x_i)^2}}{\sigma_x} \quad (20)$$

où σ_x est l'écart-type du champ cible calculé sur le jeu d'entraînement. La normalisation permet de comparer des variables d'unités et de variabilités différentes (par exemple le géopotentiel en m^2s^{-2} et la température en K) sur une même échelle. Un NRMSE de 0 correspond à une reconstruction parfaite ; un NRMSE de 1 signifie que l'erreur du modèle est du même ordre que la variabilité naturelle du champ.

B.2 ACC (Anomaly Correlation Coefficient)

La corrélation de l'anomalie mesure la capacité du modèle à reproduire les structures spatiales du champ, en comparant les anomalies prédites et observées par rapport à la climatologie (moyenne temporelle par point de grille et par variable, calculée sur le jeu d'entraînement) :

$$\text{ACC} = \frac{\sum_i (\hat{x}_i - \bar{x})(x_i - \bar{x})}{\sqrt{\sum_i (\hat{x}_i - \bar{x})^2 \sum_i (x_i - \bar{x})^2}} \quad (21)$$

où $\bar{x}$ désigne la climatologie. Un ACC de 1 indique une corrélation parfaite entre les anomalies prédites et réelles. En prévision opérationnelle, l'Organisation météorologique mondiale (OMM) considère qu'un ACC inférieur à 0,6 correspond au seuil en dessous duquel la prévision n'est plus utile.

B.3 SSIM (Structural Similarity Index)

L'indice de similarité structurelle, issu du traitement d'images, évalue la ressemblance entre deux champs en combinant trois composantes calculées sur des fenêtres locales glissantes :

$$\text{SSIM}(\hat{x}, x) = l(\hat{x}, x) \cdot c(\hat{x}, x) \cdot s(\hat{x}, x) \quad (22)$$

avec :

$$l = \frac{2\mu_{\hat{x}}\mu_x + C_1}{\mu_{\hat{x}}^2 + \mu_x^2 + C_1} \quad (\text{luminance : comparaison des moyennes locales}) \quad (23)$$

$$c = \frac{2\sigma_{\hat{x}}\sigma_x + C_2}{\sigma_{\hat{x}}^2 + \sigma_x^2 + C_2} \quad (\text{contraste : comparaison des écarts-types locaux}) \quad (24)$$

$$s = \frac{\sigma_{\hat{x}x} + C_3}{\sigma_{\hat{x}}\sigma_x + C_3} \quad (\text{structure : comparaison des corrélations locales}) \quad (25)$$

où C_1 , C_2 , C_3 sont des constantes de stabilisation qui évitent les divisions par zéro. Le SSIM vaut 1 pour deux champs identiques. Contrairement à la MSE ou au NRMSE, qui mesurent des écarts pixel à pixel, le SSIM est sensible aux distorsions structurelles : un champ légèrement décalé spatialement peut avoir une MSE élevée mais un SSIM proche de 1 si les structures sont préservées. Cette propriété en fait une métrique particulièrement adaptée à l'évaluation de champs atmosphériques, où la position exacte d'un front ou d'un gradient importe autant que son amplitude.

C Hyperparamètres d’entraînement

Paramètre	Reconstruction	Prévision	Interpolant stochastique
Optimiseur	AdamW	AdamW	AdamW
Learning rate initial	1×10^{-3}	1×10^{-3}	1×10^{-4}
Scheduler	ReduceLROnPlateau	ReduceLROnPlateau	aucun
Patience (early stopping)	10 epochs	10 epochs	5 epochs
Batch size	32	32	16
Nombre d’epochs max	100	100	20
Dropout (bottleneck)	0.3	0.3	—
α (pondération non-obs)	0.8	—	—
λ_{∇} (gradient loss)	0.1	—	0.05
λ_a (anchor loss)	—	—	1.0
λ_{ag} (anchor grad loss)	—	—	0.05
σ_{train}	—	—	0.05
w (poids d’ancrage)	—	—	[0,5, 0,75, 1,0, 1,5]
EMA decay	—	—	0.999
Clip de gradient	—	—	1.0
N_{steps} inférence	—	—	5
σ_{infer} (stochastique)	—	—	0.01

TABLE 7 – Hyperparamètres d’entraînement pour les trois modèles.